

# Sistemas distribuidos – Message Passing Interface

Sistemas Operativos  
Segundo cuatrimestre de 2016

Ignacio Vissani → Alexis Tcach

- $N$  procesos corriendo en  $M$  equipos físicamente separados.

- $N$  procesos corriendo en  $M$  equipos físicamente separados.
- Se acabó la memoria compartida en el caso general.

Podría haberla en ciertos casos particulares, pero eso no cambia la cuestión de fondo.

- $N$  procesos corriendo en  $M$  equipos físicamente separados.
- Se acabó la memoria compartida en el caso general.  
Podría haberla en ciertos casos particulares, pero eso no cambia la cuestión de fondo.
- Los procesos sólo pueden intercambiar *mensajes*.

- $N$  procesos corriendo en  $M$  equipos físicamente separados.
- Se acabó la memoria compartida en el caso general.  
Podría haberla en ciertos casos particulares, pero eso no cambia la cuestión de fondo.
- Los procesos sólo pueden intercambiar *mensajes*.
- ¿De qué hablamos cuando hablamos de mensajes?

# Pasaje de mensajes en el mundo real

- ¿Qué primitivas necesitamos?

# Pasaje de mensajes en el mundo real

- ¿Qué primitivas necesitamos?
- ¿Cómo formalizamos la semántica de cada una?

# Pasaje de mensajes en el mundo real

- ¿Qué primitivas necesitamos?
- ¿Cómo formalizamos la semántica de cada una?
- ¿Cómo representamos los datos en los mensajes?



# Pasaje de mensajes en el mundo real

- ¿Qué primitivas necesitamos?
- ¿Cómo formalizamos la semántica de cada una?
- ¿Cómo representamos los datos en los mensajes?
- ¿Dónde están los mensajes que están “en vuelo”?

# Pasaje de mensajes en el mundo real

- ¿Qué primitivas necesitamos?
- ¿Cómo formalizamos la semántica de cada una?
- ¿Cómo representamos los datos en los mensajes?
- ¿Dónde están los mensajes que están “en vuelo”?
- Enorme diversidad de hardware y software de base.

# Pasaje de mensajes en el mundo real

- ¿Qué primitivas necesitamos?
- ¿Cómo formalizamos la semántica de cada una?
- ¿Cómo representamos los datos en los mensajes?
- ¿Dónde están los mensajes que están “en vuelo”?
- Enorme diversidad de hardware y software de base.
- Necesitamos elegir y adoptar *middleware* apropiado.

# Pasaje de mensajes en el mundo real

- ¿Qué primitivas necesitamos?
- ¿Cómo formalizamos la semántica de cada una?
- ¿Cómo representamos los datos en los mensajes?
- ¿Dónde están los mensajes que están “en vuelo”?
- Enorme diversidad de hardware y software de base.
- Necesitamos elegir y adoptar *middleware* apropiado.
- En la materia usaremos MPI (Message Passing Interface).

# ¿Qué es MPI?

- Es un libro.



# ¿Qué es MPI?

- Es un libro.
- Es un estándar.



# ¿Qué es MPI?

- Es un libro.
- Es un estándar.
- Es una interfase.



# ¿Qué es MPI?

- Es un libro.
- Es un estándar.
- Es una interfase.
- Es una especificación.





# ¿Qué es MPI?

- Es un libro.
- Es un estándar.
- Es una interfase.
- Es una especificación.
- No es una biblioteca.



# ¿Qué es MPI?

- Es un libro.
- Es un estándar.
- Es una interfase.
- Es una especificación.
- No es una biblioteca.
- No es una implementación.



# ¿Qué es MPI?

- Es un libro.
- Es un estándar.
- Es una interfase.
- Es una especificación.
- No es una biblioteca.
- No es una implementación.
- No es un compilador especial ni “paralelizador”.



# ¿Qué es MPI?

- Es un libro.
- Es un estándar.
- Es una interfase.
- Es una especificación.
- No es una biblioteca.
- No es una implementación.
- No es un compilador especial ni “paralelizador”.
- Es una especificación estándar de interfase para creadores, desarrolladores y usuarios de bibliotecas de pasaje de mensajes.



# Implementaciones de MPI

- Open source de propósito general
  - MPICH2
  - OpenMPI
- Open source de propósito específico
  - MVAPICH2 (redes InfiniBand)
- Comerciales y “vendor implementations”
  - HP
  - IBM
  - Microsoft
  - Muchas otras ad-hoc para su hardware particular

*Si respetamos a rajatabla el MPI Standard, nuestro código debería funcionar correctamente en cualquier implementación.*

- En MPI, *rank* es el número que identifica a cada proceso.

# Communicators y ranks

- En MPI, *rank* es el número que identifica a cada proceso.
- Un communicator es una organización lógica que define cuáles procesos pueden comunicarse con cuáles otros.

# Communicators y ranks

- En MPI, *rank* es el número que identifica a cada proceso.
- Un communicator es una organización lógica que define cuáles procesos pueden comunicarse con cuáles otros.
- Permite separar los procesos en grupos y/o armar topologías (lógicas) convenientes para el patrón de comunicaciones.



# Communicators y ranks

- En MPI, *rank* es el número que identifica a cada proceso.
- Un communicator es una organización lógica que define cuáles procesos pueden comunicarse con cuáles otros.
- Permite separar los procesos en grupos y/o armar topologías (lógicas) convenientes para el patrón de comunicaciones.
- Casi todas las primitivas reciben uno como parámetro.

# Communicators y ranks

- En MPI, *rank* es el número que identifica a cada proceso.
- Un communicator es una organización lógica que define cuáles procesos pueden comunicarse con cuáles otros.
- Permite separar los procesos en grupos y/o armar topologías (lógicas) convenientes para el patrón de comunicaciones.
- Casi todas las primitivas reciben uno como parámetro.
- El communicator `MPI_COMM_WORLD` ya viene creado “gratis”, e incluye a todos los procesos, con *ranks* que van de 0 a  $N - 1$ .

- Básicas (inicialización, finalización, quién-soy, etc).
  - `Init()`, `Finalize()`, ...
  - `Comm_rank()`, `Comm_size()`, ...
- *Point-to-point communication*
  - `Send()`, `Recv()`, ...
  - `Isend()`, `Irecv()`, ...
- *Collective communication*
  - `Barrier()`, `Bcast()`, ...
  - `Scatter()`, `Gather()`, ...
- Otras más avanzadas
  - Tipos de datos compuestos
  - RMA (acceso a memoria remota)
  - Creación dinámica de procesos...

# Cómo hace un programa que usa MPI

- Utilizaremos wrappers para **python**

# Cómo hace un programa que usa MPI

- Utilizaremos wrappers para **python**
- Interface orientada a objetos

# Cómo hace un programa que usa MPI

- Utilizaremos wrappers para **python**
- Interface orientada a objetos
- Misma interface que la utilizada en C++

# Cómo hace un programa que usa MPI

- Utilizaremos wrappers para **python**
- Interface orientada a objetos
- Misma interface que la utilizada en C++
- Utiliza para serializar los objetos las librerías de módulo `pickle`

# Cómo hace un programa que usa MPI

- Utilizaremos wrappers para **python**
- Interface orientada a objetos
- Misma interface que la utilizada en C++
- Utiliza para serializar los objetos las librerías de módulo `pickle`
- Luego muy fácil: `from mpi4py import MPI`



# Cómo ejecutar un programa que usa MPI

- Usando el programa `mpiexec`.

# Cómo ejecutar un programa que usa MPI

- Usando el programa `mpiexec`.
- Ejemplo: `mpiexec -np 8 python <programa.py>`

# Cómo ejecutar un programa que usa MPI

- Usando el programa `mpiexec`.
- Ejemplo: `mpiexec -np 8 python <programa.py>`
- Con `-np` (o simplemente `-n`) se ajusta la cantidad de procesos.

# Cómo ejecutar un programa que usa MPI

- Usando el programa `mpiexec`.
- Ejemplo: `mpiexec -np 8 python <programa.py>`
- Con `-np` (o simplemente `-n`) se ajusta la cantidad de procesos.
- Por defecto se corre todo en localhost.

# Cómo ejecutar un programa que usa MPI

- Usando el programa `mpiexec`.
- Ejemplo: `mpiexec -np 8 python <programa.py>`
- Con `-np` (o simplemente `-n`) se ajusta la cantidad de procesos.
- Por defecto se corre todo en localhost.
- Hay opciones para indicar en qué hosts ejecutar, cuántos procesos ejecutar en cada host, etc.

- ¿Qué quería decir *bloqueante*?

- ¿Qué quería decir *bloqueante*?
- ¿Qué quería decir *no bloqueante*?

- ¿Qué quería decir *bloqueante*?
- ¿Qué quería decir *no bloqueante*?
- Revisemos algunos ejemplos.



# Bloqueante vs. no bloqueante en SDs

- ¿Qué significa **exactamente** “bloqueante”?

# Bloqueante vs. no bloqueante en SDs

- ¿Qué significa **exactamente** “bloqueante”?
- ¿Qué significa **exactamente** “no bloqueante”?

# Bloqueante vs. no bloqueante en SDs

- ¿Qué significa **exactamente** “bloqueante”?
- ¿Qué significa **exactamente** “no bloqueante”?
- En sistemas distribuidos estas nociones se complican.

# Bloqueante vs. no bloqueante en SDs

- ¿Qué significa **exactamente** “bloqueante”?
- ¿Qué significa **exactamente** “no bloqueante”?
- En sistemas distribuidos estas nociones se complican.
- ¿Por qué se complican?

# Bloqueante vs. no bloqueante en SDs

- ¿Qué significa **exactamente** “bloqueante”?
- ¿Qué significa **exactamente** “no bloqueante”?
- En sistemas distribuidos estas nociones se complican.
- ¿Por qué se complican?

# Bloqueante vs. no bloqueante en SDs

- ¿Qué significa **exactamente** “bloqueante”?
- ¿Qué significa **exactamente** “no bloqueante”?
- En sistemas distribuidos estas nociones se complican.
- ¿Por qué se complican?
- ¿Qué sucede entre un send “acá” y un receive “allá”?  
¿Por dónde pasa el mensaje?

# Bloqueante vs. no bloqueante en MPI

- ¿Cómo define “bloqueante” el MPI Standard?
- ¿Qué otros conceptos similares existen?
- Bloqueante
- Sincrónico
- Inmediato
- Ready
- Buffered
- (¿¿**Cuál** buffer??)
- Ver Request, Test(), Wait(), Cancel()

Más info:

- <https://pythonhosted.org/mpi4py/>